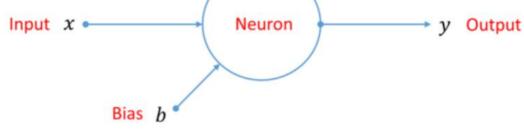
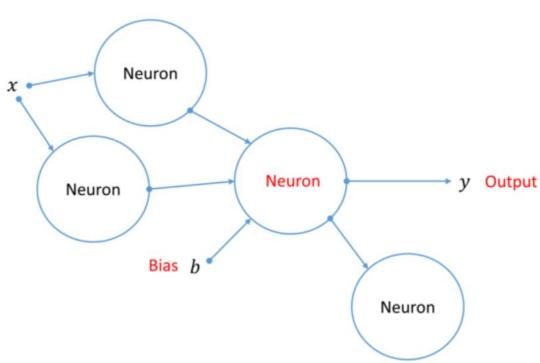
인공신경망 퍼셉트론의 이해

인공 신경 세포(Artificial Neuron)

- 뉴런
 - _ 입력
 - 편향(bias)




- 신경망(network)
 - 뉴런의 연결



입력과 출력


- 편향(bias)
 - 편향을 조정해 출력을 맞춤




Input x	Output y
Size of house	Price
Time spent for studying	Score in exam

뉴런 연산

• 뉴런 식




• 가중치와 편향




Python

행렬 곱 연산




활성화

- 활성화 함수
 - 뉴런의 출력 값을 정하는 함수

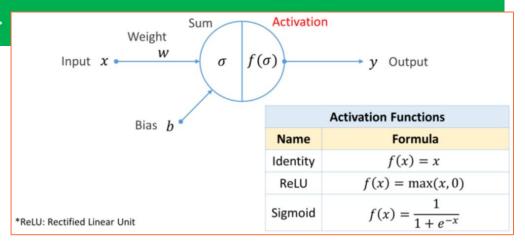


활성화 함수 ReLU, sigmoid

- ReLU(교재 p43) 위된
 - Rectified(정류된) Linear Unit(선형 함수, y=x를 의미)
 - 선형 함수를 정류하여 0 이하는 모두 0으로 한 함수
 - max(x, 0) Mbx(ロ,メ)を フィン
 - _ 양수만 사용
 - 2010년 이후
 - 층이 깊어질수록(deep) 많이 활용
 - 양수를 그대로 반환하므로 값의 왜곡이 적어지는 효과
 - 토론토 대학 힌트 교수
- Sigmoid
 - s자 형태의곡선이라는 의미
 - 예전에 많이 사용



다양한 활성화 함수 종류



Activation Functions

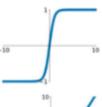
Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$



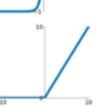
tanh

tanh(x)



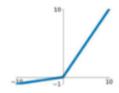
ReLU

 $\max(0,x)$



Leaky ReLU

 $\max(0.1x, x)$

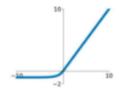


Maxout

 $\max(w_1^T x + b_1, w_2^T x + b_2)$

ELU

$$\begin{cases} x & x \ge 0\\ \alpha(e^x - 1) & x < 0 \end{cases}$$




Different Activation Functions and their Graphs

입출력의 예

- 출력 함수로
 - 동일(identity) 함수(또는 리니어 함수)를 적용

$$y = f(\sigma) = f(w \cdot x + b) = w \cdot x + b$$

with **identity** (or **linear**) activation functions




	1 /
1	1
<u></u>	1

f	(x)	=	x	
_				

Input x	Output y
0	$y = f(2 \cdot 0 + 1) = 1$
1	$y = f(2 \cdot 1 + 1) = 3$
2	$y = f(2 \cdot 2 + 1) = 5$

일반화된 인공신경망




활성화 함수와 편향


- 결과 값이 임계 값 역할
 - 결과가 임계 값 이상이면 활성화
 - 결과가 임계 값 미만이면 비활성화

Input layer


Output layer



Perceptron Unit




입력 2개, 출력 3개인 신경망 연산




인공신경망의 시그모이드 함수

- 활성화 함수의 예
 - 시그모이드 함수
 - 출력 값이 (0~1)



가중치

• 3 × 3의 가중치 실수



인공 신경망 행렬 연산


입력의 특징(x₁ x₂ x₃ ... x_i)과 입력의 자료 수


• 특징 n개가 있는 뉴런 신경망에서 하나의 출력 계산

어장는 입작이

✓ 샘플 수 1개에 대한 계산

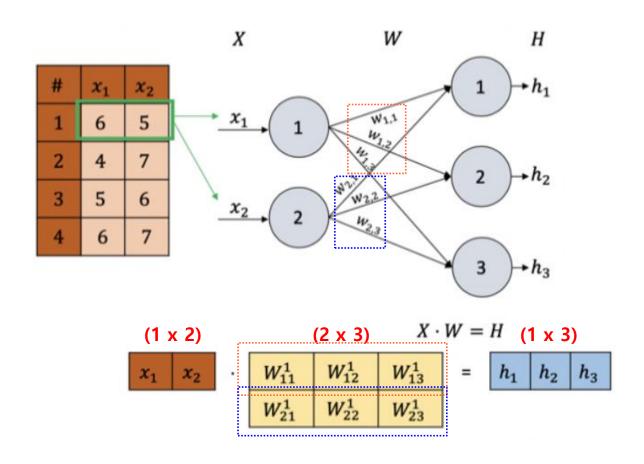
✓ 샘플 수 s개에 대한 계산






신경망 행렬 계산


- 특징 2개
 - 샘플 수 4



뉴런 계산









$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$$
 (9 12 15)

© sacko

하나의 출력 뉴런 연산

Input layer

• 활성화 함수로 시그모이드 함수 적용


Output layer

 $z(x) = w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4 + b$ $g(z) = \frac{1}{1 + e^{-z}}$

층과 가중치

• 뉴런 층과 가중치 층

뉴런이 있는 층



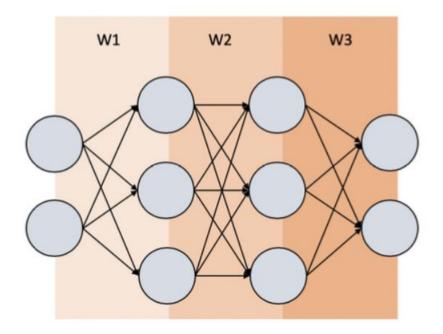




Figure 7. Layers of neuron vs Layers of weights

행령의 다른 표현

- 입력을 오른쪽 행렬에 배치
- 가중치는 왼쪽 행렬에 배치
- 곱의 순서도 변환

Using multiple observations





활성화 함수 그리기

실습 파일

- 파일 생성
 - 06-neuron-activation-dense.ipynb

자연수와 자연수의 지수 승


- e
 - 자연수, 오일러 수
 - 2.71828
- $y = e^{-x}$
- $y = e^x$

```
[76] import numpy as np
np.e
```

2.718281828459045

```
[77] import numpy as np
import matplotlib.pylab as plt
pyploff

plt.figure(figsize=(6, 4))
x = np.linspace(-8, 8, 100)
plt.plot(x, np.exp(-x), 'b==')
= plt.plot(x, np.exp(x), 'r-.')
```




시그모이드 함수

- S자 곡선
 - (0, 1) 사이의 값


$$h(x) = \underbrace{\frac{1}{1 + e^{-x}}}$$

[5] np.e

□ 2.718281828459045



[<matplotlib.lines.Line2D at 0x7f93b4130cc0>]



Python

ReLU 함수

- X
 - 0, 음수면 0
 - 양수면 x


$$h(x) = \begin{cases} 0 & (x \le 0) \\ x & (x > 0) \end{cases}$$

```
[45] 1 import numpy as np
2 import matplotlib.pylab as plt
3

4 def relu_func(x): # ReLU(Rectified Linear Unit, 정류된 선형 유닛) 함수
5 return np.maximum(0, x)
6 #return (x>0)*x # same
7

8 # ReLU 함수 그리기
9 plt.figure(figsize=(8, 6))
10 x = np.linspace(-8, 8, 100)
11 plt.plot(x, relu_func(x))
```

[<matplotlib.lines.Line2D at 0x7f93b409b748>]



시그모이드 ReLU 함께 그리기

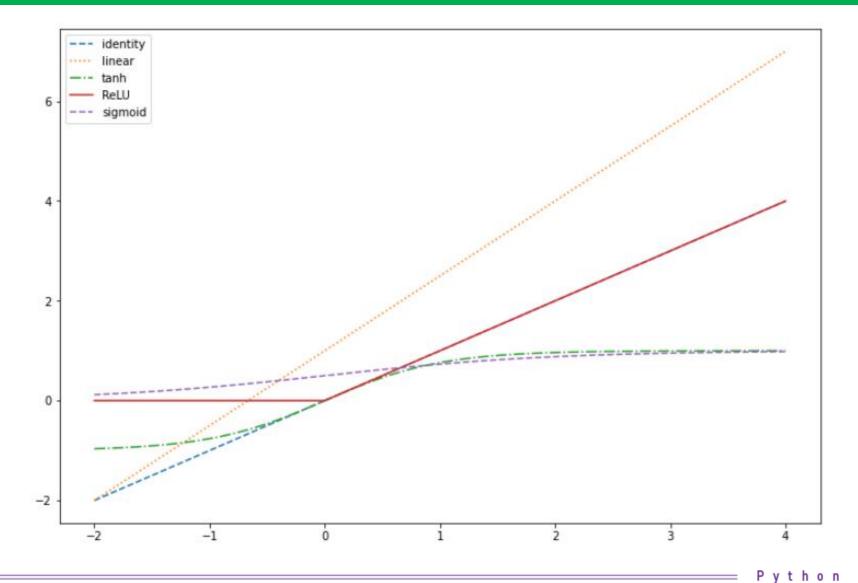
```
ReLU
                                            sigmoid
                                    3.5
                                    3.0
                                    2.5
import numpy as np
import matplotlib.pylab as plt
                                    2.0
# ReLU(Rectified Linear Unit
# (정류된 선형 유닛) 함수
                                   1.5
def relu func(x):
    return np.maximum(0, x)
                                   1.0
    \#return (x>0)*x \# same
def sigm func(x): # sigmoid 함수
                                   0.5
    return 1 / (1 + np.exp(-x))
                                   0.0
# 그래프 그리기
plt.figure(figsize=(8, 6))
x = np.linspace(-4, 4, 100)
y = np.linspace(-0.2, 2, 100)
plt.plot(x, relu func(x), linestyle=':', label="ReLU")
plt.plot(x, sigm func(x), linestyle='--', label="sigmoid")
plt.legend(loc='upper left')
```

Python

다양한 활성화 함수

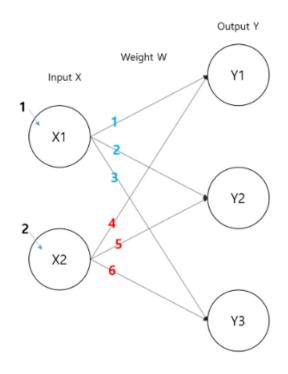
```
import numpy as np
import matplotlib.pylab as plt
def identity func(x): # 항등함수
    return x
def linear func(x): # 1차함수
    return 1.5 * x + 1 # a기울기(1.5), Y절편b(1) 조정가능
def tanh func(x): # TanH 함수
    return np.tanh(x)
def relu func(x): # ReLU(Rectified Linear Unit, 정류된 선형 유닛) 함수
    return np.maximum(0, x)
    \#return (x>0)*x \# same
def sigm func(x): # sigmoid 함수
    return 1 / (1 + np.exp(-x))
# 그래프 그리기
plt.figure(figsize=(12, 8))
x = np.linspace(-2, 4, 100)
plt.plot(x, identity func(x), linestyle='--', label="identity")
plt.plot(x, linear func(x), linestyle=':', label="linear")
plt.plot(x, tanh func(x), linestyle='-.', label="tanh")
plt.plot(x, relu func(x), linestyle='-', label="ReLU")
plt.plot(x, sigm func(x), linestyle='--', label="sigmoid")
plt.legend(loc='upper left')
```

활성화 함수 결과



인공 신경망 행렬 연산 코드

계산 사례



$$X * W = Y$$

1 x 2 * 2 x 3 = 1 x 3

$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$$
 (9 12 15)

▼ 뉴런의 행렬 연산

```
[14] x = [[1, 2]] \leftarrow 274

w = [[1, 2, 3], [4, 5, 6]]


y = tf.matmul(x, w)

y.numpy()
```

□ array([[9, 12, 15]], dtype=int32)

신경망 행렬 계산

- 특징 2개
 - 샘플 수 4



특징 2, 샘플 수 4개의 행렬 연산


```
[15] \times = [[6, 5]]
     w = [[1, 2, 3], [4, 5, 6]]
     y = tf.matmul(x, w)
     y.numpy()
r→ array([[26, 37, 48]], dtype=int32)
[16] \times = [[6, 5], [4, 7], [5, 6], [6, 7]]
     w = [[1, 2, 3], [4, 5, 6]]
     y = tf.matmul(x, w)
     y.numpy()
 r→ array([[26, 37, 48],
             [32, 43, 54],
             [29, 40, 51],
             [34, 47, 60]], dtype=int32)
```

행렬의 순서를 바꾼 계산

가중치와 입력 값의 순서도 수정

```
[78] \#x = [[6, 5], [4, 7], [5, 6], [6, 7]]
\#w = [[1, 2, 3], [4, 5, 6]]
w = [[1, 4], [2, 5], [3, 6]]
x = [[6, 4, 5, 6], [5, 7, 6, 7]]
y = tf.matmul(w, x)
y.numpy()
```

Using multiple observations




논리 게이트 AND OB XOB 신경망 구현

AND 게이트 구현

- 뉴런 구조
 - 입력 2개, 편향, 출력 1
 - 구할 값
 - 가중치 2개와 편향 1개

x1	x2	у
0	0	0
0	1	0
1	0	0
1	1	1

(Output)



Output of neuron = Y = f(w1. X1 + w2. X2 + b)






Figure 2: Single Layer Perceptron Network

```
# tf.keras 를 이용한 AND 네트워크 계산
import numpy as np
x = \text{np.array}([[1,1], [1,0], [0,1], [0,0]])
y = np.array([[1], [0], [0], [0]]) جِعِع
model = tf.keras.Sequential([
    tf.keras.layers.Dense(units=1, activation='sigmoid', input_shape=(2,))
                         BZ1 17H
])
                                  0~1 KF017#
                                                       POHY 나는 나는 아니 아니는 아니를
model.compile(optimizer=tf.keras.optimizers.SGD(Ir=0.3), loss='mse')
model.summary()
                                             对行为
Model: "sequential_4"
                                                                   Input Layer
                                                                                        Output Layer
Layer (type) 👍
                           Output Shape
                                                    Param #
                                                                                W2
dense 6 (Dense)
                           (None, 1)
Total params: 3
                                                                                W1
                                                                                                Output
Trainable params: 3
Non-trainable params: 0
                                                                              bias
history = model.fit(x, y, epochs=400, batch_size=1)
                                                                  Figure 2: Single Layer Perceptron Network
4/4 [=========== ] - Os 1ms/step - loss: 0.0145
Epoch 372/400
4/4 [======= ] - Os 2ms/step - loss: 0.0144
Epoch 373/400
                                                                                           Python
4/4 [======= ] - 0s 2ms/step - loss: 0.0144
Epoch 374/400
```

손실 값 그래프와 결과 예측

```
[54] # 3.34 2-레이어 XOR 네트워크의 loss 변화를 선 그래프로 표시 import matplotlib.pyplot as plt plt.plot(history.history['loss'])
```






OR 게이트 구현

• 여러분이 직접 해 보세요.


```
Import numpy us up
 x= np_ ~ v v v y ( [[ 1, 1], [1, 0], [ 0, 0])
 >= NB-WALK X(((1) (1) (1) (1) (1)
 model = +f. kerus. Sequential(C
       +f. keros, layers, Dense (Units = 1, activation= 'sigmoid', input_shape = (7, )),
                  Loptimizer = +F. keras.
model (optimizers. SGD(Ir=0.3), loss='msel)
model. Symmaty()
history= model. fit (x, x, epochs=400, batch-5ize=1)
```

XOR 문제


- 하나의 퍼셉트론으로는 XOR 게이트는 불가능
 - 마빈 민스키와 시모어 페퍼트가 증명
 - 첫 AI 겨울의 계기



x_1	x_2	у
0	0	0
0	1	1
1	0	1
1	1	1



x_1	x_2	у
0	0	0
0	1	0
1	0	0
1	1	1



x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	0

XOR 해결

- 뉴런 3 개의 2층으로 가능
 - 모델이 구해야 할 총 매개변수(가중치와 편향)
 - · 3 * 2 + 3 * 1 = 9개

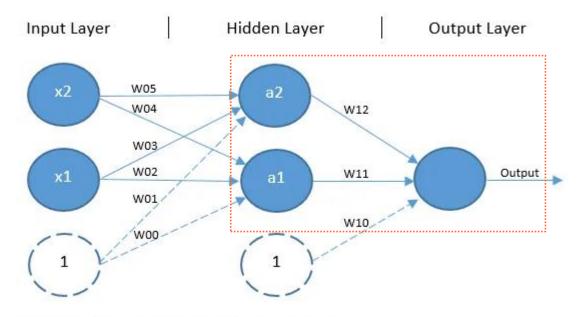


Figure 4: Multilayer Pereceptron Architecture for XOr

Sequential 모델

• Dense 층

- 가장 기본적인 층
- 인자 units, activation
 - 뉴런 수와 활성화 함수
- 인자 input_shape
 - 첫 번째 층에서만 정의
 - 입력의 차원을 명시
 - (2,)
 - _ 2개의 입력을 받는 1차원




Figure 4: Mult layer Pereceptron Architecture for XOr

Sequential 모델과 딥러닝 구조


- 입력, 은닉, 출력 층
 - 패러미터 수
 - (입력측 뉴런 수 + 1) * (출력측 뉴런 수)

```
x = np.array([[1,1], [1,0], [0,1], [0,0]])

y = np.array([[0], [1], [1], [0]])
```

```
model = tf.keras.Sequential([
    tf.keras.layers.Dense(units=2; activation='sigmoid', input_shape=(2,)),
    tf.keras.layers.Dense(units=1; activation='sigmoid')
```

Input Layer Hidden Layer



dense_2 (Dense)	(None, 2)	6
dense_3 (Dense)	(Nøne, 1)	.3

Total params: 9 Trainable params: 9 Non-trainable params: 0

Model: "sequential 1"

Output Layer





Figure 4: Multilayer Pereceptron Architecture for Xor

XOR 게이트 구현 소스

```
# 3.27 tf.keras 를 이용한 XOR 네트워크 계산
import tensorflow as tf
import numpy as np
x = np.array([[1,1], [1,0], [0,1], [0,0]])
y = np.array([[0], [1], [1], [0]])
model = tf.keras.Sequential([
    tf.keras.layers.Dense(units=2, activation='sigmoid', input shape=(2,)),
    tf.keras.layers.Dense(units=1, activation='sigmoid')
1)
model.compile(optimizer=tf.keras.optimizers.SGD(lr=0.3), loss='mse')
model.summary()
# 3.28 tf.keras 를 이용한 XOR 네트워크 학습
history = model.fit(x, y, epochs=2000, batch size=1)
# 3.29 tf.keras 를 이용한 XOR 네트워크 평가
print(model.predict(x))
# 3.30 XOR 네트워크의 가중치와 편향 확인
for weight in model.weights: Epoch 1999/2000
    print(weight)
                                Epoch 2000/2000
                                4/4 [================= ] - Os 1ms/step - loss: 0.0017
                               [[0.04060324]
                               [0.9609237]
                                [0.96031225]
                                [0.04571233]]
                                <tf.Variable 'dense_2/kernel:0' shape=(2, 2) dtype=float32, numpy=
                                array([[ 5.378626 , -5.299518 ],
                                     [-5.518024 , 5.0764313]], dtype=float32)>
                                <tf.Variable 'dense_2/blas:0' shape=(2,) dtype=float32, numpy=array([-3.0511274, -2.8576972], dtype=float32)>
                                <tf. Variable 'dense_3/kernel:0' shape=(2, 1) dtype=float32, numpy=
                                array([[7.6903753],
                                     [7.7518315]], dtype=float32)>
                                <tf.Variable 'dense_3/bias:0' shape=(1,) dtype=float32, numpy=array([-3.8067687], dtype=float32)>
```

가중치와 model.weights



XOR 모델의 학습 과정 시각화

- 손실(loss) 또는 오류 값의 변화
 - 가로는 에폭의 수
 - 학습 횟수가 증가하면서 계속 손실은 작아짐

```
# 3.34 2-레이어 XOR 네트워크의 loss 변화를 선 그래프로 표시 import matplotlib.pyplot as plt
```

plt.plot(history.history['loss'])

